

Transformer

1. 整体结构

获取输入句子的每一个单词的表示向量 X $\left\{ \begin{array}{l} \text{单词的 Embedding} \\ \text{单词位置的 Embedding} \end{array} \right.$

↓ 表示向量矩阵

Encoder: 6个 Encoder block

↓ 编码信息矩阵 C

Decoder

2. Transformer 的输入

X : 单词 Embedding + 位置 Embedding

2.1 单词 Embedding: 可采用 word2vec, Glove 等算法预训练得到, 也可在 Transformer 中训练得到

2.2 位置 Embedding: PE 和前者维度相同

$$PE(pos, 2i) = \sin(pos / 10000^{2i/d})$$

$$PE(pos, 2i+1) = \cos(pos / 10000^{2i/d})$$

低维维度
奇数维度 单词在句中位置 PE 的维度

好处: ① 可处理 训练中未遇到的长度

② 更容易地计算相对位置

$$\sin(pos+k) = \sin(pos) \cos(k) + \cos(pos) \sin(k)$$

正弦

$$\cos(pos+k) = \cos(pos)\cos(k) - \sin(pos)\sin(k)$$

$pos+k$ 处的编码可表示为 pos 处编码的线性组合


可以用此公式算出 2 个词之间的距离 k 。

3. Self-Attention

Encoder: 含 1 个 Multi-Head Attention

Decoder: 含 2 个, 其中 1 个用来 Masked.

3.1 self-Attention 结构



3.2 Q, K, V 计算

→ 学习的权重矩阵

$$X \times W_Q = Q \quad (\text{查询: 找什么})$$

$$X \times W_K = K \quad (\text{键值: 我身上有什么标签})$$

$$X \times W_V = V \quad (\text{值: 我实际携带的内容})$$

3.3 Self-Attention 的输出

$$A_{ij} = \frac{\exp(\frac{Q_i \cdot K_j^T}{\sqrt{d_k}})}{\sum_l \exp(\frac{Q_i \cdot K_l^T}{\sqrt{d_k}})}$$

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

QK^T : $n \times n$ (n 为单词数), 可以表示单词间的 attention 强度

3.4 Multi-Head Attention (从不同角度去理解这句话)

$X \rightarrow h$ 个不同的 self-Attention 中



h 个输出矩阵 Z



$Z \xleftarrow{\text{Linear 拼接}}$

4. Encoder

Multi-Head Attention



Add & Norm



Feed forward



Add & Norm

4.1. Add & Norm

→ Layer Norm ($X + \text{MultiHeadAttention}(X)$)

→ Layer Norm ($X \boxed{+} \text{Feed Forward}(X)$)

层归一化:
加速收敛

↓
残差连接: 有助于缓解梯度消失问题;
并让网络只关注当前差异

4.2 feed Forward

2层的全连接层

一层激活函数为 Relu

二层不用激活函数


$$\max(0, xw_1 + b)w_2 + b$$

4.3 组成 Encoder

$$X_{n \times d} \rightarrow \text{Encoder block} \rightarrow O(n \times d)$$

多个 Encoder block 叠加组成 Encoder

5. Decoder



5.1 Masked Multi-Head Attention

顺序翻译

预测第 i 个输出时, 将 $i+1$ 之后的遮住

在 softmax 之前 Mask


5.2 第2个 Multi-Head Attention

K, V 用 **Encoder 的编码信息矩阵 C** 计算的

Q 用上一个 Decoder block 的输出 Z 计算

好处: 每个单词可用到 Encoder 所有单词的信息

5.3 Softmax 预测输出



流程示例

1) 数据处理:

例: "女生擦刘海"

ID: 1256 875 9527

向量: [1, 0] [2, 1] [2, 3]

位置: 0 1 2

$$\text{Word Embedding } E = \begin{bmatrix} 1 & 0 \\ 2 & 1 \\ 2 & 3 \end{bmatrix}$$

2) 加入位置信息:

$$X = E + P = \begin{bmatrix} 1 & 0 \\ 2 & 1 \\ 2 & 3 \end{bmatrix} + \begin{bmatrix} \sin 0 & \cos 0 \\ \sin 1 & \cos 1 \\ \sin 2 & \cos 2 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 2.4 & 1.5 \\ 2.9 & 2.6 \end{bmatrix}$$

P怎么算:

当pos=0时:

$$P_E(pos, z_i) = \sin\left(\frac{pos}{10000^{2i/d}}\right) = \sin\left(\frac{0}{10000^{2 \times 0/d}}\right) = 0$$

$$P_E(pos, z_{i+1}) = \cos\left(\frac{pos}{10000^{2i/d}}\right) = \cos\left(\frac{0}{10000^{2 \times 0/d}}\right) = 1$$

12) 计算 Q, K, V

$$Q = X W_Q = \begin{bmatrix} 1 & 1 \\ 2.8 & 1.5 \\ 2.9 & 2.6 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 2.8 & 4.3 \\ 2.9 & 2.6 \end{bmatrix}$$

$$K = X W_K = \begin{bmatrix} 1 & 1 \\ 2.8 & 1.5 \\ 2.9 & 2.6 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 5.6 & 1.5 \\ 3.8 & 2.6 \end{bmatrix}$$

$$V = X W_V = \begin{bmatrix} 1 & 1 \\ 2.8 & 1.5 \\ 2.9 & 2.6 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 2.8 & 4.3 \\ 2.9 & 5.5 \end{bmatrix}$$

14) 计算 token 之间的相关程度

$$Q K^T = \begin{bmatrix} 1 & 2 \\ 2.8 & 4.3 \\ 2.9 & 2.6 \end{bmatrix} \begin{bmatrix} 2 & 5.6 & 3.8 \\ 1 & 1.5 & 2.6 \end{bmatrix} = \begin{bmatrix} 4 & 8.6 & 11 \\ 9.9 & 22.1 & 27.4 \\ 11.3 & 24.5 & 31.1 \end{bmatrix}$$

“持”与“女孩”的相关度

缩放 (Scale):

$$S = \frac{Q K^T}{\sqrt{d}} = \frac{L}{\sqrt{2}} = \begin{bmatrix} 2.8 & 6.1 & 7.8 \\ 7 & 15.6 & 19.4 \\ 4 & 17.3 & 22 \end{bmatrix}$$

15) Softmax:

注意力权重矩阵 A = softmax(S) =

$$\begin{bmatrix} 0 & 0.2 & 0.8 \\ 0 & 0 & 1 \end{bmatrix}$$

$$\frac{e^{7.8}}{e^{2.8} + e^{6.1} + e^{7.8}}$$

$$\begin{pmatrix} 0 & 0 & 1 \end{pmatrix}$$

(6) 加权求和

$$\text{输出矩阵 } Z = AV = \begin{pmatrix} 0 & 0.2 & 0.8 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 2 \\ 2.4 & 4.3 \\ 2.9 & 5.5 \end{pmatrix}$$

$$= \begin{pmatrix} 2.9 & 5.3 \\ 2.9 & 5.5 \\ 2.9 & 5.3 \end{pmatrix}$$

(7) 多头注意力机制

$W_{k1} \quad W_{k1} \quad W_{k1}$

$W_{k2} \quad W_{k2} \quad W_{k2}$

$W_{k3} \quad W_{k3} \quad W_{k3}$

$$\text{head}_1 = \begin{pmatrix} 2.9 & 5.3 \\ 2.9 & 5.5 \\ 2.9 & 5.5 \end{pmatrix}$$

$$\text{head}_2 = \begin{pmatrix} 12.3 & -4.1 \\ 3.7 & 4.2 \\ 3.4 & 2.6 \end{pmatrix}$$

$$\text{head}_3 = \begin{pmatrix} 4.2 & -2.2 \\ 1.4 & 3.7 \\ 2.7 & 1.4 \end{pmatrix}$$

Multi Head (Q, K, V)

$$= \text{Concat}(\text{head}_1, \text{head}_2, \text{head}_3) W_o$$

$$= \begin{pmatrix} 9.7 & -0.6 \\ 3.5 & 6.7 \\ 4.5 & 5.0 \end{pmatrix}$$

(8) 残差连接

$$X' = X + \text{MultiHead}(Q, K, V)$$

$$= \begin{bmatrix} 1 & 1 \\ 2.4 & 1.5 \\ 2.9 & 2.6 \end{bmatrix} + \begin{bmatrix} 9.7 & -0.6 \\ 3.5 & 6.7 \\ 4.5 & 5.0 \end{bmatrix} = \begin{bmatrix} 10.7 & 0.4 \\ 6.3 & 8.2 \\ 7.4 & 7.6 \end{bmatrix}$$

19) 层归一化 (Layer Norm)

$$[10.7 \quad 0.4]$$

① 平均值: $\mu_1 = 5.55$

② 方差 $\sigma^2 = \frac{1}{2}[(10.7-5.55)^2 + (0.4-5.55)^2] \quad \sigma = 5.15$

③ 归一化: $x'_1 = \left(\frac{10.7-5.55}{5.15}, \frac{0.4-5.55}{5.15} \right) = (1, -1)$
 $\dots$

$$\hat{X} = \text{Layer Norm}(X') = \begin{bmatrix} 1 & -1 \\ -1 & 1 \\ -1 & 1 \end{bmatrix}$$

线性变化: $Y' = r\hat{X} + \beta$

110) 前馈神经网络 (FFN)

$$\text{FFN}(\hat{X}) = \max(0, \hat{X}W_1 + b_1)W_2 + b_2$$

$$= \begin{bmatrix} 3 & 0 \\ 5 & 5 \\ 5 & 5 \end{bmatrix}$$

111) 第二次残差连接

$$X'' = \hat{X} + \text{FFN}(\hat{X}) = \begin{bmatrix} 4 & -1 \\ 4 & 6 \\ 4 & 6 \end{bmatrix}$$

第 二 次 归 一 化

$$y'' = \text{Layer Norm}(x'') = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}$$