

Transformer

1. 整体结构

提取输入句子的每一个单词的表示向量 X $\left\{ \begin{array}{l} \text{单词的 Embedding} \\ \text{单词位置的 Embedding} \end{array} \right.$

↓ 表示向量矩阵

Encoder: 6个 Encoder block

↓ 编码信息矩阵 C

Decoder

2. Transformer 的输入

X : 单词 Embedding + 位置 Embedding

2.1 单词 Embedding: 可采用 word2vec, Glove 等算法预训练得到, 也可在 Transformer 中训练得到

2.2 位置 Embedding: PE 和前者维度相同

$$PE(pos, 2i) = \sin(pos / 10000^{2i/d})$$

$$PE(pos, 2i+1) = \cos(pos / 10000^{2i/d})$$

低维维度 $\swarrow$ PE 的维度
奇数维度 $\swarrow$ 单词在句中位置

好处: ① 可处理 训练中未遇到的长度

② 更容易地计算相对位置

$$\sin(pos+k) = \sin(pos) \cos(k) + \cos(pos) \sin(k)$$

积化和差

$$\cos(pos+k) = \cos(pos)\cos(k) - \sin(pos)\sin(k)$$


$pos+k$ 处的编码可表示为 pos 处编码的线性组合
可以用此公式算出 2 个词之间的距离 k 。

3. Self-Attention

Encoder: 含 1 个 Multi-Head Attention

Decoder: 含 2 个, 其中 1 个用来 Masked.

3.1 self-Attention 结构



3.2 Q, K, V 计算

→ 要学习的权重矩阵

$$X \times W_Q = Q \quad (\text{查询: 找什么})$$

$$X \times W_K = K \quad (\text{键值: 我身上有什么标签})$$

$$X \times W_V = V \quad (\text{值: 我实际携带的内容})$$

3.3 Self-Attention 的输出

$$A_{ij} = \frac{\exp(\frac{Q_i \cdot K_j^T}{\sqrt{d_k}})}{\sum_l \exp(\frac{Q_i \cdot K_l^T}{\sqrt{d_k}})}$$

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

QK^T : $n \times n$ (n 为单词数), 可以表示单词间的 attention 强度

3.4 Multi-Head Attention

$X \rightarrow h$ 个不同的 self-Attention 中



h 个输出矩阵 Z



$Z \xleftarrow{\text{Linear 拼接}}$

4. Encoder

Multi-Head Attention



Add & Norm



Feed forward



Add & Norm

4.1. Add & Norm

→ Layer Norm ($X + \text{MultiHeadAttention}(X)$)

→ Layer Norm ($X \boxed{+} \text{Feed Forward}(X)$)

层归一化:
加速收敛

↓
残差连接: 有助于缓解梯度消失问题;
并让网络只关注当前差异

4.2 Feed Forward

2层的无连接层

一层激活函数为 Relu

二层不用激活函数


$$\max(0, xw_1 + b)w_2 + b$$

4.3 组成 Encoder

$$X_{n \times d} \rightarrow \boxed{\text{Encoder block}} \rightarrow O(n \times d)$$

多个 Encoder block 叠加组成 Encoder

5. Decoder



5.1 Masked Multi-Head Attention

顺序翻译

预测第 i 个输出时, 将 $i+1$ 之后的遮住

在 softmax 之前 Mask

5.2 第2个 Multi-Head Attention.

K, V 用 Encoder 的编码信息矩阵 C 计算的

Q 用上一个 Decoder block 的输出 Z 计算

好处: 每个单词可用到 Encoder 所有单词的信息

5.3 Softmax 预测输出

